

Выводы по предварительной обработке данных

1. Проблема пропущенных данных.

В исходном датасете пропущенные значения не обнаружены, поэтому удаление строк или заполнение пропусков не потребовалось.

2. Обработка категориальных данных.

Признаки sex, smoker и region преобразованы в числовой вид. В коде рассмотрены One-Hot Encoding и Ordinal Encoding; для дальнейшей работы сохранены данные после Ordinal Encoding.

3. Анализ распределения целевой переменной, обработка выбросов.

Целевая переменная charges имеет правостороннюю асимметрию. По boxplot видны выбросы, но они связаны с реальными группами наблюдений, особенно с курящими клиентами, поэтому выбросы не удалялись.

4. Разбиение данных на тренировочную, валидационную и тестовую выборки.

Данные разделены на train, validation и test в пропорции 60/20/20. Для регрессии использована стратификация по интервалам charges с учетом smoker, чтобы сохранить похожее распределение целевой переменной.

5. Процедуры валидации.

Для промежуточной оценки модели подготовлена validation-выборка. Подбор гиперпараметров далее можно выполнять на train с помощью GridSearchCV и KFold, а test использовать только для финальной проверки.