

Черновой отчет по проекту

Этапы 1-5: EDA, модели, ансамбли и сравнительный анализ

1. Разведочный анализ и предобработка данных

Шаг Загрузка и первичная проверка данных

Исходный датасет содержит 1338 наблюдений и 7 столбцов. Были выделены количественные признаки age, bmi, children, категориальные признаки sex, smoker, region и целевая переменная charges.

Шаг Проверка пропусков

Проверка `df.isna().sum()` показала 0 пропущенных значений. Поэтому удаление строк или заполнение пропусков не потребовалось.


Картинка Распределение целевой переменной

Большая часть значений charges сосредоточена в нижнем диапазоне, а справа виден длинный хвост дорогих страховых случаев. Это показывает правостороннюю асимметрию целевой переменной.




Картинка Boxplot целевой переменной

На boxplot видны высокие значения charges. Их не удаляли автоматически, потому что такие наблюдения могут быть реальными страховыми случаями, а не ошибками данных.



Картинка Распределение charges по признаку smoker

График показывает, что у курящих клиентов значения charges заметно выше. Признак smoker оказался одним из ключевых факторов, поэтому он учитывался при стратифицированном разделении данных.




Шаг Логарифмирование target

Из-за правосторонней асимметрии целевая переменная была преобразована через $\log_{1p}(\text{charges})$. Модели обучаются на логарифмированном target, а метрики считаются после обратного преобразования $\exp m1$.

Картинка Распределение после логарифмирования

После логарифмирования распределение target становится более компактным и менее скошенным. Это помогает моделям стабильнее работать с дорогими страховыми случаями.




Шаг Обработка категориальных признаков

Категориальные признаки sex, smoker и region были обработаны через OneHotEncoder. Кодировщик обучался только на X_{train} , затем применялся к X_{val} и X_{test} , что исключает утечку данных.

Корреляции количественных признаков после логарифмирования

Корреляционная матрица построена только по количественным признакам. После логарифмирования связи с target становятся интерпретируемее, а анализ не искажается искусственным порядком категорий.



Метрики Размеры итоговых выборок

После стратифицированного разделения получены выборки train 801 строка, validation 268 строк и test 268 строк. После OneHotEncoding используется 8 признаков.

Вывод Вывод по главе 1

Предобработка выполнена корректно: пропусков нет, выбросы проанализированы, target логарифмирован, категориальные признаки обработаны через OneHotEncoder после разделения данных, а train validation test сохраняют похожую структуру по charges и smoker.


2. Базовые модели и проблема переобучения

Шаг Построение одиночного дерева решений

Во второй главе построена базовая модель DecisionTreeRegressor. Сначала рассматривается дерево без ограничения глубины, чтобы показать проблему переобучения и получить точку отсчета.

Картинка Структура дерева решений

Визуализация первых уровней дерева показывает, что модель строит последовательные разбиения по признакам. Без ограничений дерево может становиться слишком глубоким и запоминать обучающую выборку.



Шаг Оптимизация гиперпараметров

Для борьбы с переобучением использовались `max_depth`, `min_samples_split`, `min_samples_leaf` и `criterion`. Подбор выполнялся через `KFold` и `GridSearchCV` в два этапа: широкий поиск, затем уточнение рядом с лучшими значениями.

Картинка Лучшие параметры одиночного дерева

Для одиночного дерева лучшая комбинация ограничивает глубину и размер листьев. Это уменьшает переобучение и делает модель устойчивее, чем дерево без ограничений.

Лучшие параметры DecisionTreeRegressor


Параметр	Значение
criterion	absolute_error
max_depth	10
min_samples_split	2
min_samples_leaf	8

Метрики Метрики оптимизированного одиночного дерева

На тестовой выборке оптимизированное одиночное дерево получило $R^2 = 0.8399$, $MAE = 1723.63$ и $RMSE = 4564.54$. Метрики рассчитаны в исходной шкале `charges` после `expm1`.

Картинка График остатков одиночного дерева

График остатков показывает, как распределяются ошибки модели. У дерева видна дискретность предсказаний, потому что внутри каждого листа модель возвращает одно усредненное значение.



Вывод Вывод по главе 2

Одиночное дерево дает понятную и интерпретируемую базовую модель, но остается чувствительным к структуре обучающей выборки. Ограничение глубины и минимального числа объектов в листьях снижает переобучение, но полностью проблему разброса не устраняет.

3. Ансамбли: Bagging и Random Forest

Шаг Переход к ансамблям

В третьей главе одиночное дерево сравнивается с ансамблевыми моделями. Цель ансамблей - снизить разброс предсказаний за счет объединения нескольких деревьев.

Шаг BaggingRegressor

BaggingRegressor обучает несколько деревьев на bootstrap-подвыборках и усредняет их ответы. Для него выполнен двухэтапный подбор гиперпараметров `n_estimators`, `max_samples`, `max_features` и параметров базового дерева.

Картинка Лучшие параметры Bagging

Для Bagging подбирались как параметры ансамбля, так и параметры базового дерева. Усреднение нескольких деревьев снижает разброс по сравнению с одиночной моделью.

Лучшие параметры BaggingRegressor

Параметр	Значение
<code>n_estimators</code>	50
<code>max_samples</code>	0.6
<code>max_features</code>	1.0
<code>bootstrap</code>	True
<code>estimator__max_depth</code>	5
<code>estimator__min_samples_split</code>	2
<code>estimator__min_samples_leaf</code>	2

Метрики Метрики BaggingRegressor

На тестовой выборке Bagging получил $R^2 = 0.8475$, $MAE = 2010.78$ и $RMSE = 4454.60$. По R^2 и $RMSE$ модель немного лучше одиночного дерева, но MAE выше.

Картинка График остатков Bagging

График остатков Bagging показывает характер ошибок ансамбля на тестовой выборке. Усреднение деревьев сглаживает часть резких ошибок, но дорогие страховые случаи остаются сложными для прогноза.



Шаг RandomForestRegressor

RandomForestRegressor использует bootstrap-подвыборки и случайный выбор признаков при построении разбиений. Это делает деревья менее похожими друг на друга и помогает дополнительно снижать разброс.

Картинка Лучшие параметры Random Forest

Для случайного леса дополнительно подбирались `max_features` и `csp_alpha`. За счет случайного выбора признаков деревья становятся менее коррелированными.

Лучшие параметры RandomForestRegressor

Параметр	Значение
n_estimators	100
max_depth	6
min_samples_split	2
min_samples_leaf	2
max_features	0.8
bootstrap	True
ccp_alpha	0.0

Метрики Метрики Random Forest

На тестовой выборке Random Forest получил $R^2 = 0.8485$, $MAE = 1964.76$ и $RMSE = 4440.05$. Это лучший R^2 и $RMSE$ среди моделей до добавления бустинга.

Картинка График остатков Random Forest

График остатков Random Forest показывает похожую структуру ошибок, но за счет декорреляции деревьев модель немного стабильнее по итоговым метрикам.



Картинка Важность признаков Random Forest

Наиболее важными признаками для Random Forest оказались smoker_yes, age и bmi. Это согласуется с EDA: курение, возраст и индекс массы тела сильнее всего связаны со стоимостью страховки.



Картинка Важность признаков Bagging

Bagging показывает похожую картину важности признаков: smoker_yes, age и bmi оказывают основной вклад в прогноз. Это подтверждает устойчивость найденных закономерностей.



Вывод Вывод по главе 3

Ансамблевые модели помогают снизить разброс одиночного дерева. Bagging и Random Forest улучшают R2 и RMSE, а случайный лес показывает немного лучший результат за счет случайного подмножества признаков.

4. Градиентный бустинг

Шаг Идея градиентного бустинга

Градиентный бустинг строит деревья последовательно. Каждое новое дерево исправляет ошибки уже построенного ансамбля, поэтому модель постепенно уменьшает функцию потерь.

Шаг Двухэтапный подбор гиперпараметров

Для GradientBoostingRegressor сначала выполнен широкий RandomizedSearchCV, затем уточненный поиск рядом с лучшими найденными значениями. После широкого поиска лучший CV R2 был 0.8444, после уточнения - 0.8448.

Картинка Лучшие параметры Gradient Boosting

После уточненного поиска лучшими стали $n_estimators = 100$, $learning_rate = 0.05$, $max_depth = 3$, $min_samples_leaf = 7$, $min_samples_split = 4$, $subsample = 0.9$ и $max_features = 1.0$.

Лучшие параметры GradientBoostingRegressor


Параметр	Значение
subsample	0.9
n_estimators	100
min_samples_split	4
min_samples_leaf	7
max_features	1.0
max_depth	3
learning_rate	0.05

Метрики Метрики GradientBoostingRegressor

На validation модель получила $R^2 = 0.8719$, $MAE = 2041.35$ и $RMSE = 4415.52$. На test результат составил $R^2 = 0.8483$, $MAE = 1938.55$ и $RMSE = 4443.66$.


Картинка Кривые обучения Gradient Boosting

Кривая обучения показывает изменение R^2 при добавлении деревьев. Лучший шаг на validation был около 83 деревьев, после чего дальнейшее увеличение числа деревьев уже не дает заметного выигрыша.



Картинка График остатков Gradient Boosting

График остатков показывает, что бустинг хорошо работает на основной массе наблюдений, но дорогие страховые случаи остаются наиболее сложной зоной прогноза.




Картинка Факт против прогноза Gradient Boosting

Точки около диагонали означают точные предсказания. Отклонения от диагонали показывают ошибки модели, особенно на больших значениях charges.



Картинка Важность признаков Gradient Boosting

Самыми важными признаками для бустинга стали smoker_yes, age, children и bmi. Признак smoker_yes снова оказался главным фактором стоимости страховки.



Вывод Вывод по главе 4

Градиентный бустинг показал качество почти на уровне Random Forest: $R^2 = 0.8483$ против 0.8485 у случайного леса. По RMSE он немного уступил Random Forest, но оказался лучше Bagging по MAE. Последовательное исправление ошибок дало устойчивую модель, но преимущество над случайным лесом оказалось минимальным.

5. Сравнение всех моделей

Шаг Объединение результатов

В отдельном ноутбуке 05_Comparison.ipynb объединены результаты всех построенных моделей: одиночного дерева, Bagging, Random Forest и Gradient Boosting. Все модели сравниваются на одной и той же тестовой выборке в исходной шкале charges.


Картинка Сводная таблица метрик

Сводная таблица показывает, что Random Forest имеет лучший R^2 и RMSE, а Gradient Boosting почти не уступает ему. Одиночное дерево показывает лучший MAE, но хуже по R^2 и RMSE.

Сводная таблица метрик моделей на тестовой выборке			
Модель	R^2	MAE	RMSE
Random Forest	0.8485	1964.76	4440.05
Gradient Boosting	0.8483	1938.55	4443.66
Bagging	0.8475	2010.78	4454.60
Одиночное дерево	0.8399	1723.63	4564.54


Картинка Сравнение моделей по R^2

По R^2 лидируют Random Forest и Gradient Boosting. Их результаты практически совпадают, поэтому качество этих двух ансамблей можно считать очень близким.



Картинка Сравнение MAE и RMSE

По RMSE лучший результат у Random Forest, почти такой же у Gradient Boosting. По MAE минимальная ошибка у одиночного дерева, но это не означает лучшую устойчивость модели на всех типах ошибок.




Картинка Скорость инференса

По скорости предсказания быстрее всего работают Gradient Boosting и одиночное дерево. Bagging и Random Forest медленнее, потому что используют много деревьев в ансамбле.




Картинка Факт против прогноза

Графики факт против прогноза показывают, что все модели хорошо описывают основную массу наблюдений. На дорогих страховых случаях отклонения от диагонали становятся заметнее.




Картинка Распределение абсолютных ошибок

Boxplot абсолютных ошибок показывает, что у моделей есть отдельные крупные промахи. Именно они сильнее всего влияют на RMSE.




Картинка Остатки всех моделей

Графики остатков помогают увидеть систематические ошибки. Самая сложная зона для всех моделей - высокие значения charges, где разброс ошибок увеличивается.




Картинка Ошибки по группам smoker

Сравнение ошибок по группам smoker показывает, отличаются ли ошибки для курящих и некурящих клиентов. Это важно, потому что smoker является самым сильным фактором стоимости страховки.




Картинка Ошибки по диапазонам charges

Ошибки по диапазонам charges показывают, что дорогие страховые случаи сложнее прогнозировать. На высоких значениях target абсолютная ошибка закономерно увеличивается.




Картинка Сравнение важности признаков

Сравнение встроенной важности признаков показывает, что smoker_yes, age и bmi стабильно остаются ключевыми факторами почти во всех моделях.




Картинка SHAP-анализ Random Forest

SHAP-анализ подтверждает глобальную важность признаков smoker_yes, age и bmi. Он показывает не только важность признака, но и направление его влияния на прогноз.




Картинка SHAP bar plot

SHAP bar plot показывает средний абсолютный вклад признаков в предсказания Random Forest. Этот график удобен как компактная версия глобальной интерпретации.



Картинка Локальное SHAP-объяснение

Локальное SHAP-объяснение показывает, какие признаки сильнее всего повлияли на прогноз для одного конкретного клиента. Это полезно для интерпретации отдельных предсказаний.



Метрики Итоговая таблица метрик

Одиночное дерево: $R^2 = 0.8399$, MAE = 1723.63, RMSE = 4564.54. Bagging: $R^2 = 0.8475$, MAE = 2010.78, RMSE = 4454.60. Random Forest: $R^2 = 0.8485$, MAE = 1964.76, RMSE = 4440.05. Gradient Boosting: $R^2 = 0.8483$, MAE = 1938.55, RMSE = 4443.66.

Вывод Финальный вывод

Если ориентироваться на R^2 и RMSE, лучшей моделью является Random Forest, но Gradient Boosting практически не уступает ему. Bagging улучшает одиночное дерево по R^2 и RMSE, но не по MAE. Самые сложные ошибки возникают на дорогих страховых случаях, а ключевыми признаками остаются smoker_yes, age и bmi.