

Черновой отчет по проекту

Этапы 1-3: EDA, базовое дерево, Bagging и Random Forest

1. Разведочный анализ и предобработка данных

Шаг Загрузка и первичная проверка данных


Исходный датасет содержит 1338 наблюдений и 7 столбцов. Были выделены количественные признаки age, bmi, children, категориальные признаки sex, smoker, region и целевая переменная charges.

Шаг Проверка пропусков

Проверка `df.isna().sum()` показала 0 пропущенных значений. Поэтому удаление строк или заполнение пропусков не потребовалось.


Картинка Распределение целевой переменной

Большая часть значений charges сосредоточена в нижнем диапазоне, а справа виден длинный хвост дорогих страховых случаев. Это показывает правостороннюю асимметрию целевой переменной.




Картинка Boxplot целевой переменной

На boxplot видны высокие значения charges. Их не удаляли автоматически, потому что такие наблюдения могут быть реальными страховыми случаями, а не ошибками данных.



Картинка Распределение charges по признаку smoker

График показывает, что у курящих клиентов значения charges заметно выше. Признак smoker оказался одним из ключевых факторов, поэтому он учитывался при стратифицированном разделении данных.




Шаг Логарифмирование target

Из-за правосторонней асимметрии целевая переменная была преобразована через $\log_{1p}(\text{charges})$. Модели обучаются на логарифмированном target, а метрики считаются после обратного преобразования expm1 .

Картинка Распределение после логарифмирования

После логарифмирования распределение target становится более компактным и менее скошенным. Это помогает моделям стабильнее работать с дорогими страховыми случаями.




Шаг Обработка категориальных признаков

Категориальные признаки sex, smoker и region были обработаны через OneHotEncoder. Кодировщик обучался только на X_{train} , затем применялся к X_{val} и X_{test} , что исключает утечку данных.

Корреляции количественных признаков после логарифмирования

Корреляционная матрица построена только по количественным признакам. После логарифмирования связи с target становятся интерпретируемее, а анализ не искажается искусственным порядком категорий.



Метрики Размеры итоговых выборок

После стратифицированного разделения получены выборки train 801 строка, validation 268 строк и test 268 строк. После OneHotEncoding используется 8 признаков.

Вывод Вывод по главе 1

Предобработка выполнена корректно: пропусков нет, выбросы проанализированы, target логарифмирован, категориальные признаки обработаны через OneHotEncoder после разделения данных, а train validation test сохраняют похожую структуру по charges и smoker.


2. Базовые модели и проблема переобучения

Шаг Построение одиночного дерева решений

Во второй главе построена базовая модель DecisionTreeRegressor. Сначала рассматривается дерево без ограничения глубины, чтобы показать проблему переобучения и получить точку отсчета.

Картинка Структура дерева решений

Визуализация первых уровней дерева показывает, что модель строит последовательные разбиения по признакам. Без ограничений дерево может становиться слишком глубоким и запоминать обучающую выборку.



Шаг Оптимизация гиперпараметров


Для борьбы с переобучением использовались `max_depth`, `min_samples_split`, `min_samples_leaf` и `criterion`. Подбор выполнялся через KFold и GridSearchCV в два этапа: широкий поиск, затем уточнение рядом с лучшими значениями.

Метрики Метрики оптимизированного одиночного дерева

На тестовой выборке оптимизированное одиночное дерево получило $R^2 = 0.8399$, $MAE = 1723.63$ и $RMSE = 4564.54$. Метрики рассчитаны в исходной шкале `charges` после `expm1`.

Картинка График остатков одиночного дерева

График остатков показывает, как распределяются ошибки модели. У дерева видна дискретность предсказаний, потому что внутри каждого листа модель возвращает одно усредненное значение.



Вывод Вывод по главе 2

Одиночное дерево дает понятную и интерпретируемую базовую модель, но остается чувствительным к структуре обучающей выборки. Ограничение глубины и минимального числа объектов в листьях снижает переобучение, но полностью проблему разброса не устраняет.

3. Ансамбли: Bagging и Random Forest

Шаг Переход к ансамблям

В третьей главе одиночное дерево сравнивается с ансамблевыми моделями. Цель ансамблей - снизить разброс предсказаний за счет объединения нескольких деревьев.

Шаг BaggingRegressor

BaggingRegressor обучает несколько деревьев на bootstrap-подвыборках и усредняет их ответы. Для него выполнен двухэтапный подбор гиперпараметров `n_estimators`, `max_samples`, `max_features` и параметров базового дерева.

Метрики Метрики BaggingRegressor

На тестовой выборке Bagging получил $R^2 = 0.8475$, $MAE = 2010.78$ и $RMSE = 4454.60$. По R^2 и $RMSE$ модель немного лучше одиночного дерева, но MAE выше.

Картинка График остатков Bagging

График остатков Bagging показывает характер ошибок ансамбля на тестовой выборке. Усреднение деревьев сглаживает часть резких ошибок, но дорогие страховые случаи остаются сложными для прогноза.



Шаг RandomForestRegressor

RandomForestRegressor использует bootstrap-подвыборки и случайный выбор признаков при построении разбиений. Это делает деревья менее похожими друг на друга и помогает дополнительно снижать разброс.

Метрики Метрики Random Forest

На тестовой выборке Random Forest получил $R^2 = 0.8485$, $MAE = 1964.76$ и $RMSE = 4440.05$. Это лучший R^2 и $RMSE$ среди трех рассмотренных моделей.


Картинка График остатков Random Forest

График остатков Random Forest показывает похожую структуру ошибок, но за счет декорреляции деревьев модель немного стабильнее по итоговым метрикам.




Картинка Сравнение моделей по R2

По R2 на тестовой выборке Random Forest и Bagging немного превосходят одиночное дерево. Разница небольшая, но она показывает эффект ансамблирования.



Картинка Сравнение MAE и RMSE

По RMSE ансамбли дают лучший результат, что означает снижение крупных ошибок. При этом одиночное дерево имеет меньший MAE, поэтому выбор модели зависит от того, какую ошибку важнее минимизировать.



Шаг OOB-оценка

Для Bagging и Random Forest дополнительно рассматривается OOB-оценка. Она использует объекты, которые не попали в bootstrap-подвыборку конкретного дерева. Для одиночного дерева OOB не применяется.

Картинка Важность признаков Random Forest

Наиболее важными признаками для Random Forest оказались smoker_yes, age и bmi. Это согласуется с EDA: курение, возраст и индекс массы тела сильнее всего связаны со стоимостью страховки.



Картинка Важность признаков Bagging

Bagging показывает похожую картину важности признаков: smoker_yes, age и bmi оказывают основной вклад в прогноз. Это подтверждает устойчивость найденных закономерностей.



Вывод Вывод по главе 3

Ансамблевые модели действительно помогают снизить разброс одиночного дерева. Лучший R2 и RMSE получил Random Forest, но преимущество над Bagging и одиночным деревом небольшое. Главные признаки для всех деревьев связаны с курением, возрастом и bmi.

Итог

Вывод Общий итог по этапам 1-3

В проекте выполнены EDA и корректная предобработка данных, построена базовая модель дерева решений, затем реализованы ансамбли Bagging и Random Forest. Модели сравнивались на одной тестовой выборке в исходной шкале charges, что делает сравнение честным и интерпретируемым.