

Выводы по предварительной обработке данных

1. Проблема пропущенных данных.

В исходном датасете пропущенные значения не обнаружены, поэтому удаление строк или заполнение пропусков не потребовалось.

2. Обработка категориальных данных.

Признаки sex, smoker и region преобразованы в числовой вид. В коде рассмотрены One-Hot Encoding и Ordinal Encoding; для дальнейшей работы сохранены данные после Ordinal Encoding.

3. Анализ распределения целевой переменной, обработка выбросов.

Целевая переменная charges имеет правостороннюю асимметрию. По boxplot видны выбросы, но они связаны с реальными группами наблюдений, особенно с курящими клиентами, поэтому выбросы не удалялись.

4. Разбиение данных на тренировочную, валидационную и тестовую выборки.

Данные разделены на train, validation и test в пропорции 60/20/20. Для регрессии использована стратификация по интервалам charges с учетом smoker, чтобы сохранить похожее распределение целевой переменной.

5. Процедуры валидации.

Для промежуточной оценки модели подготовлена validation-выборка. Подбор гиперпараметров далее можно выполнять на train с помощью GridSearchCV и KFold, а test использовать только для финальной проверки.

Выводы по базовой модели Decision Tree

1. Деревья решений для задач регрессии.

Для базовой модели был выбран `DecisionTreeRegressor`. Дерево делит пространство признаков на области и в каждом листе прогнозирует числовое значение страховых выплат `charges`.

2. Построение предикатов и критерии качества разбиения.

На примере жадного алгоритма дерево последовательно выбирает условия разбиения по признакам `age`, `bmi`, `children`, `smoker`, `sex` и `region`. В `GridSearchCV` сравнивались критерии `squared_error` и `absolute_error`.

3. Проблема переобучения решающего дерева.

Дерево без ограничения глубины почти идеально запоминает `train`, но хуже обобщает закономерности на `validation`. Это показывает типичную проблему переобучения одиночного дерева.

4. Разложение ошибки модели на смещение и разброс.

Маленькая глубина дает высокое смещение, а слишком большая глубина увеличивает разброс. Ручной анализ `max_depth` показал эту зависимость, после чего `KFold` и `GridSearchCV` подобрали более устойчивые параметры модели.

5. Визуальный анализ ошибок модели.

График остатков помогает увидеть систематические ошибки. Модель лучше справляется с массовыми недорогими полисами, а наиболее крупные ошибки чаще возникают для дорогих страховых случаев.